

Tesina inferenza
Noleggio bici a Washington D.C. (2011-2012)

LUCA SAVOJA

Contents

1	Descrizione dataset	3
2	Panoramica delle variabili	5
3	Inferenza con una variabile	8
3.1	Inferenza per un parametro di tendenza centrale	8
3.2	Campioni appaiati	12
3.3	Test Funzionali	14
3.3.1	Test di Kolmogorov	14
3.3.2	Test Chi-quadrato	15
4	Inferenza con due variabili	17
4.1	Inferenza per parametri di tendenza centrale	17
4.2	Correlazione	21
4.2.1	Variabili Quantitative	21
4.2.2	Variabili Qualitative	23
4.3	Analisi della varianza	25
5	Regressione	28
5.1	Regressione Lineare	28
5.1.1	Regressione con trasformate	32
5.1.2	Regressione di Poisson	34
5.1.3	Regressione Logistica	36
5.2	Regressione multipla	39
5.2.1	Modelli additivi generalizzati	44
5.2.2	Regressione Logistica Multipla	46
6	Metodi di smorzamento	48
6.1	Stimatore di nucleo	48
6.2	Stimatore di nucleo bivariato	51
7	Massima Verosimiglianza	55

1 Descrizione dataset

Le analisi che verranno presentate in questo elaborato faranno riferimento ad un dataset che riporta le informazioni relative al noleggio di biciclette all'interno dell'area urbana di Washington D.C. negli anni 2011 e 2012. La maggior parte delle analisi saranno condotte sul 2012 ed il lettore verrà avvisato qualora ci dovessimo servire anche dei dati relativi al 2011.

Le osservazioni sono giornaliere ed ammontano a 731, rispettivamente 365 per il 2011 e 366 per il 2012 ¹. Per ciascun giorno avremo le determinazioni delle seguenti variabili:

1. **dteday**: Data
2. **season**: Stagione in cui si trova il giorno di riferimento (Winter, Spring, Summer, Fall)
3. **yr**: Variabile dicotomica che assume valore 0 per il 2011 e 1 per il 2012
4. **mnth**: Mese in cui si trova il giorno di riferimento
5. **holiday**: Variabile dicotomica che assume la modalità "Yes" se il giorno di riferimento è festivo altrimenti assume la modalità "No"
6. **weekday**: Giorno della settimana del giorno di riferimento
7. **workingday**: Variabile dicotomica che assume la modalità "Yes" se il giorno di riferimento è lavorativo altrimenti assume la modalità "No"
8. **weathersit**: Variabile che indica la qualità del clima nel giorno di riferimento (Good, Moderate, Bad).
9. **temp**: Variabile che indica la temperatura media del giorno di riferimento espressa in °C
10. **atemp**: Variabile che indica la temperatura media percepita del giorno di riferimento espressa in °C
11. **hum**: Variabile che indica l'umidità media del giorno di riferimento espressa in percentuale
12. **windspeed**: Variabile che indica la velocità media del vento nel giorno di riferimento espressa in Km/h
13. **casual**: Numero di clienti che hanno noleggiato la bici quel giorno senza possedere un abbonamento (clienti occasionali)
14. **registered**: Numero di clienti possessori di abbonamento che hanno noleggiato la bici quel giorno
15. **cnt**: Numero totale di clienti (somma delle variabili casual e registered)

¹I dati del nostro dataset dunque presentano stagionalità ed autocorrelazione pertanto tutte le analisi verranno condotte con la consapevolezza di ciò.

Il dataset si presenta nel seguente modo:

```
> head(dataset)
```



	dteday	season	yr	mnth	holiday	weekday	workingday
1	2011-01-01	winter	0	January	No	Saturday	No
2	2011-01-02	winter	0	January	No	Sunday	No
3	2011-01-03	winter	0	January	No	Monday	Yes
4	2011-01-04	winter	0	January	No	Tuesday	Yes
5	2011-01-05	winter	0	January	No	Wednesday	Yes
6	2011-01-06	winter	0	January	No	Thursday	Yes

	weathersit	temp	atemp	hum	windspeed	casual
1	Moderate	8.175849	7.999250	0.805833	10.749882	331
2	Moderate	9.083466	7.346774	0.696087	16.652113	131
3	Good	1.229108	-3.499270	0.437273	16.636703	120
4	Good	1.400000	-1.999948	0.590435	10.739832	108
5	Good	2.666979	-0.868180	0.436957	12.522300	82
6	Good	1.604356	-0.608206	0.518261	6.000868	88

	registered	cnt
1	654	985
2	670	801
3	1229	1349
4	1454	1562
5	1518	1600
6	1518	1606

2 Panoramica delle variabili


Per poter comprendere al meglio le analisi che verranno fatte in questa tesina reputo utile introdurre le variabili che tratteremo attraverso alcune loro rappresentazioni grafiche.² Partendo dalle variabili qualitative possiamo farci un'idea sulla loro distribuzione attraverso i loro grafici a barre.




²N.B. La panoramica delle variabili riguarderà solo le osservazioni relative al 2012 poiché la quasi totalità delle analisi riguarderà queste osservazioni.

Queste due variabili qualitative non sono le uniche presenti nel nostro dataset ma sono le uniche per le quali ha senso visualizzare la loro distribuzione.


Adesso passiamo alle variabili quantitative. Qui reputo utile visualizzare i diagrammi a scatole e baffi di tutte e 7 le variabili.



Adesso vediamo due matrici di diagrammi di dispersione per vedere la relazione che vi è tra le variabili evidenziando anche il coefficiente di correlazione per ciascuna coppia.



Dalla prima matrice osserviamo un risultato ovvio ovvero una relazione lineare quasi perfetta tra la temperatura e la temperatura percepita. Inoltre reputo molto interessante porre l'attenzione sulla relazione che vi è tra la temperatura e i clienti occasionali e tra la temperatura e i clienti registrati (abbonati). In entrambi i casi la nuvola dei punti sembra seguire un andamento lineare positivo ma per quanto riguarda i clienti occasionali la nuvola si distribuisce lungo una retta con inclinazione maggiore rispetto ai clienti registrati, questo significa che con l'aumentare della temperatura vediamo una maggiore elasticità tra i clienti registrati rispetto a quelli occasionali, ovvero all'aumentare della temperatura vedremo un aumento maggiore nel numero dei clienti registrati rispetto quelli casuali. Per quanto riguarda la relazione tra i clienti totali e i clienti registrati invece notiamo che vi è una certa linearità, questo dimostra come la maggior parte dei clienti siano registrati e quelli occasionali abbiano un peso minimo sulla clientela complessiva. E' bene evidenziare che negli ultimi tre grafici (in basso a destra) le nuvole dei punti appaiono biforcute, questo è dovuto alla stagionalità dei nostri dati.



Dalla seconda matrice possiamo notare come l'umidità non sembri avere un impatto significativo sul numero giornaliero di clienti. E' interessante osservare invece come ad alti valori di vento corrispondano solo bassi valori di clienti casuali, cosa che non si verifica con i clienti registrati. Questo vuol dire che quando fa molto vento i clienti occasionali preferiscono trovare mezzi di trasporto alternativi mentre gli abbonati decideranno lo stesso di noleggiare la bici. Tutto questo ha senso perché dopo aver pagato un abbonamento è normale che si sia più propensi ad usufruire del servizio.

3 Inferenza con una variabile

3.1 Inferenza per un parametro di tendenza centrale

In questa sezione procederemo a fare inferenza relativamente alla media e alla mediana della variabile temp utilizzando diversi tipi di test.

Test t di student

Iniziamo applicando il test t di student il quale prevede l'assunzione di normalità della variabile e poniamo come ipotesi nulla $H_0: \mu = 16$.

```
> t.test(temp, alternative = "two.sided", mu = 16)
```

One Sample t-test

data: temp

t = -0.71234, **df** = 365, p-value = 0.4767

alternative hypothesis: true **mean** is not **equal** to 16

95 percent confidence interval:

14.84098 16.54262

sample estimates:

mean of x

15.6918

Il p-value assume il valore 0.4767, dunque ci troviamo all'interno dell'area di accettazione dell'Ipotesi Nulla. A conferma di ciò possiamo vedere che la nostra ipotesi ($H_0: \mu = 16$) si trova all'interno dell'intervallo di confidenza fissato il livello di significatività al 5%.

Test dei segni

In questo caso facciamo inferenza sulla mediana così da non restringere troppo il modello statistico e non facciamo nessuna assunzione sulla variabile (approccio distribution-free). Poniamo come Ipotesi Nulla $H_0: \lambda = 16$.

```
> binom.test(length(temp[temp > 16]), length(temp),  
p = 1/2, alternative = "two.sided")
```

Exact binomial test

data: length(temp[temp > 16]) and length(temp)

number of successes = 184, number of trials = 366, p-value = 0.9583

alternative hypothesis: true probability of success is not equal to 0.5

95 percent confidence interval:

0.4502999 0.5551200

sample estimates:

probability of success

0.5027322

Il p-value assume il valore 0.9583 dunque anche in questo caso accettiamo l'Ipotesi Nulla.

Visualizziamo l'intervallo di confidenza.

```
> sd[qbinom(0.025, length(temp), 1/2)]
```

```
[1] 14.01165
```

```
> sd[qbinom(0.975, length(temp), 1/2)]
```

```
[1] 17.65415
```

Possiamo notare come sia il p-value che l'ampiezza dell'intervallo siano maggiori rispetto al t test, questo perché le assunzioni fatte nel test dei segni sono molto più morbide ed il processo inferenziale risulta più incerto.

Test di Wilcoxon

In questo caso l'unica assunzione che faremo sarà quella di simmetria della variabile rispetto alla mediana ed anche qui poniamo come Ipotesi Nulla

$H_0: \lambda = 16$.

```
> wilcox.test(temp, alternative = "two.sided", mu = 16,
  conf.int = TRUE)
```

Wilcoxon signed rank test with continuity correction

```
data: temp
V = 32236, p-value = 0.507
alternative hypothesis: true location is not equal to 16
95 percent confidence interval:
 14.85369 16.59662
sample estimates:
(pseudo)median
 15.70685
```

Anche qui il p-value assume un valore abbastanza alto e dunque accettiamo l'Ipotesi che la mediana sia uguale a 16. In questo caso possiamo notare come sia il p-value che l'ampiezza dell'intervallo di confidenza siano molto simili a quelli ottenuti con il t test, questo dimostra che l'assunzione di simmetria aumenta l'efficienza della procedura distribution-free.

Test di permutazione dei segni

Con questo test assumiamo non solo che la variabile sia simmetrica rispetto la mediana ma anche che il campione sia scambiabile. Anche qui la nostra Ipotesi Nulla è $H_0: \lambda = 16$.

```
> perm.test(temp, paired = FALSE, alternative = "two.sided",
  mu = 16)
```


Asymptotic 1-sample Permutation Test

```
data: temp
T = 1261.9, p-value = 0.476
alternative hypothesis: true mu is not equal to 16
```

Possiamo osservare come il p-value sia quasi identico a quello ottenuto con il t test (dunque accettiamo l'Ipotesi Nulla) nonostante in questo approccio non abbiamo fatto neanche l'assunzione di indipendenza delle osservazioni.

Test bootstrap

Questo test consiste nel prendere una gran numero di campioni (nel nostro caso 10000) e per ciascuno di essi se ne calcola la media così da poter creare un istogramma con tutte le medie ottenute.



Possiamo vedere dall'istogramma che la distribuzione non è centrata in 16 anche se esso non è un valore troppo lontano dal centro della distribuzione. Adesso eseguiamo il test.

```
> boot(temp, m, R = 9999, stype = "w")
```

ORDINARY NONPARAMETRIC BOOTSTRAP

Call:

```
boot(data = temp, statistic = m, R = 9999, stype = "w")
```

```

Bootstrap Statistics :
      original      bias      std. error
t1*   15.6918  0.004589596   0.4371414

```

```

> boot.ci(boot(temp, m, R = 9999, stype = "w"), conf = 0.95,
  type = c("norm", "basic", "perc", "bca"))

```

BOOTSTRAP CONFIDENCE INTERVAL CALCULATIONS
Based on 9999 bootstrap replicates

```

CALL :
boot.ci(boot.out = boot(temp, m, R = 9999, stype = "w"),
  conf = 0.95, type = c("norm", "basic", "perc", "bca"))

```

```

Intervals :
Level      Normal              Basic
95%    (14.86, 16.52 )    (14.83, 16.53 )

```

```

Level      Percentile          BCa
95%    (14.85, 16.55 )    (14.86, 16.56 )
Calculations and Intervals on Original Scale


```

Come possiamo vedere tutti e 4 gli intervalli di confidenza che otteniamo (calcolati con 4 metodi differenti) hanno un'ampiezza minore rispetto all'intervallo ottenuto con il t test e tutti e 4 contengono il valore 16, ragion per cui anche con il metodo bootstrap accettiamo l'Ipotesi Nulla.

3.2 Campioni appaiati


Adesso considereremo il dataset comprensivo dei dati relativi sia al 2011 che al 2012 e analizzeremo la variabile temp per entrambi gli anni così da vedere attraverso l'analisi per campioni appaiati se ci sono state differenze. Il 2012 è stato un anno bisestile dunque procedo a togliere il 29 febbraio così da avere due dataset di uguale lunghezza.³ Effettuiamo l'analisi visualizzando per prima cosa la stima di nucleo della differenza tra la variabile temp nel 2011 e nel 2012. Il parametro h è stato ottenuto attraverso il metodo della cross-validation (h=1.141399).

³Divido il dataset in due dataset. Il dataset "dati" relativo al 2012 e "dati1" relativo al 2011.



Da questa visualizzazione possiamo notare come la distribuzione della variabile differenza sembri essere centrata in zero.

Come seconda cosa osserviamo la distribuzione delle osservazioni attraverso il confronto tra i quantili teorici e quelli campionari, così da vedere di quanto la distribuzione della differenza si discosti dalla distribuzione di una normale.



Come ultima cosa effettuiamo un t test ponendo come Ipotesi Nulla $H_0: \mu = 0$

```
> t.test(Difference, alternative = "two.sided", mu = 0)
```

One Sample t-test

```
data: Difference
t = 3.3006, df = 364, p-value = 0.00106
alternative hypothesis: true mean is not equal to 0
95 percent confidence interval:
 0.3391749  1.3390521
sample estimates:
mean of x
 0.8391135
```

Il p-value ci dice che bisogna rifiutare l'ipotesi che la media della variabile sia zero.

3.3 Test Funzionali

3.3.1 Test di Kolmogorov


Torniamo a considerare solo il dataset relativo al 2012. Considerando soltanto il periodo invernale (`season = winter`) potremmo ipotizzare che la variabile `atemp` (temperatura percepita) abbia una distribuzione approssimabile con una distribuzione Normale. Per verificare questa ipotesi utilizziamo il test di Kolmogorov.

```
> ks.test(dati2$atemp, "pnorm", mean(dati2$atemp),
  var(dati2$atemp)^(1/2))
```

Asymptotic one-sample Kolmogorov-Smirnov test

```
data: dati2$atemp
D = 0.095236, p-value = 0.3879
alternative hypothesis: two-sided
```


Dal test risulta un p-value pari a 0.3879, dunque accettiamo l'ipotesi che la distribuzione della variabile `atemp` sia approssimabile con una Normale. Adesso procediamo a dare una rappresentazione grafica della funzione di ripartizione empirica (della variabile `atemp`) e Teorica (della Normale).



3.3.2 Test Chi-quadrato

Analizzando la variabile `workingday` ci si aspetta che circa $1/3$ dei giorni siano festivi mentre i restanti $2/3$ lavorativi. Per testare questa ipotesi utilizziamo il test Chi-quadrato così da poter confrontare i valori osservati della variabile con quelli teorici. Come prima cosa realizziamo una rappresentazione grafica che ci permette di confrontare le probabilità dei valori osservati con quelle dei valori teorici.

Distribuzione delle Probabilità: Teoriche vs Osservate per workingday



Possiamo notare una certa somiglianza tra i valori osservati e quelli teorici. Per vedere se le ipotesi fatte sulle probabilità si possono accettare effettuiamo il test Chi-quadrato.

```
> chisq.test(Counts, p = Theory.Probs)
```

Chi-squared test for given probabilities

data: Counts


X-squared = 0.39589, df = 1, p-value = 0.5292

Come c'era da immaginarsi il p-value assume un valore piuttosto alto dunque accettiamo l'ipotesi di base.

4 Inferenza con due variabili

4.1 Inferenza per parametri di tendenza centrale

Adesso procederemo ad effettuare un'analisi con due campioni relativi alla variabile `cnt`. Il dataset che useremo sarà quello che presenta i dati relativi sia al 2011 che al 2012, dunque i due campioni sono rispettivamente i valori di `cnt` per ciascun giorno del 2011 e del 2012. Sappiamo bene che i due campioni non siano indipendenti (il numero di clienti presenta stagionalità ed è presente anche autocorrelazione) ma per esercizio li considereremo tali. Per cominciare vediamo una loro rappresentazione grafica attraverso un diagramma a scatole e baffi.



Dai due diagrammi è possibile vedere come la distribuzione del secondo campione (2012) sia molto più spostata verso destra evidenziando un aumento del numero di clienti. Adesso per vedere meglio le due distribuzioni useremo metodi di stima di nucleo con parametro di smorzamento. I valori del parametro di smorzamento ricavati attraverso il metodo cross-validation sono i seguenti.


```
> hcv(cnt.1, hstart = 0.1, hend = 500)
```

```
[1] 252.063
```

```
> hcv(cnt.2, hstart = 0.1, hend = 500)
```

```
[1] 216.4861
```

Adesso visualizziamo la distribuzione della variabile sui due campioni.



Ora abbiamo un'idea più chiara della differenza che vi è tra le distribuzioni della variabile cnt nei due campioni.

Prima di fare un test t di student a due campioni procediamo col verificare l'ipotesi di omoschedasticità dei due campioni attraverso un test F di Fisher.

```
> var.test(cnt.1, cnt.2, paired = F, alternative = "two.sided")
```

F test to compare two variances

data: cnt.1 and cnt.2

F = 0.59417, num df = 364, denom df = 365, p-value = 7.9e-07

alternative hypothesis: true ratio of variances is not equal to 1

95 percent confidence interval:

0.4837396 0.7298422

sample estimates:

ratio of variances

0.5941744

Il p-value ci porta a rifiutare l'ipotesi di omoschedasticità, del resto il rapporto fra le varianze dei due campioni è pari a circa 0.59, un valore parecchio lontano da 1. Nonostante non sia possibile assumere l'omoschedasticità proseguiremo comunque implementando il test t di student (specificando all'interno del comando t.test la non omoschedasticità dei campioni). Qui l'Ipotesi Nulla è l'uguaglianza tra le medie ($H_0: \mu_1 = \mu_2$).

```
> t.test(cnt.1, cnt.2, var.equal = F, alternative = "two.sided")
```

Welch Two Sample t-test

```
data: cnt.1 and cnt.2
t = -18.578, df = 685.5, p-value < 2.2e-16
alternative hypothesis: true difference in means is not equal to 0
95 percent confidence interval:
-2426.069 -1962.276
sample estimates:
mean of x mean of y
3405.762 5599.934
```

Il p-value assume un valore molto basso dunque non possiamo accettare l'ipotesi di omogeneità delle medie dei due campioni.

Proseguiamo con altri due test, il test di Mann-Whitney e il test di Permutazione. In entrambi i casi la nostra Ipotesi Nulla riguarda la mediana della distribuzione dei due campioni ($H_0: \lambda_1 = \lambda_2$).

```
> wilcox.test(dataset$cnt ~ dataset$yr, alternative = "two.sided")
```

Wilcoxon rank sum test with continuity correction

```
data: dataset$cnt by dataset$yr
W = 22678, p-value < 2.2e-16
alternative hypothesis: true location shift is not equal to 0
```

```
> perm.test(dataset$cnt ~ dataset$yr, paired = F,
alternative = "two.sided")
```

Asymptotic 2-sample Permutation Test

```
data: dataset$cnt by dataset$yr
T = 1243103, p-value < 2.2e-16
alternative hypothesis: true mu is not equal to 0
```

In entrambi i casi otteniamo un p-value prossimo allo zero dunque rifiutiamo anche l'Ipotesi di omogeneità delle mediane.

Anche qui, come abbiamo visto nell'inferenza con una variabile, un altro test possibile è il test bootstrap.

```
> Boot.meandif <- numeric(10000)
> Boot.sample <- numeric(length(dataset$cnt))
> for (i in 1:10000) {Boot.sample <- sample(dataset$cnt,
replace = T);
+ Boot.cnt1 <- Boot.sample[c(1:length(cnt.1))];
+ Boot.cnt2 <- Boot.sample[c((length(cnt.1) + 1):length
(dataset$cnt))]; Boot.meandif[i] <- mean(Boot.cnt1)
```

```


- mean(Boot.cnt2)}
> 2 * length(Boot.meandif[Boot.meandif < mean(cnt.1)
- mean(cnt.2)]) / 10000

```

[1] 0

La significatività del test ci porta ancora una volta a rifiutare l'Ipotesi di omogeneità delle medie.

Un altro test che è possibile effettuare è quello di Kolmogorov-Smirnov. Questo test non riguarda parametri di tendenza centrale come quelli appena visti ma riguarda le funzioni di ripartizione dei due campioni. Prima di procedere con il test diamo una rappresentazione grafica delle due funzioni.



Già dal grafico possiamo vedere come le due funzioni di ripartizione empiriche siano molto differenti tra loro, procediamo effettuando il test di Kolmogorov-Smirnov.

```
> ks.test(cnt.1, cnt.2)
```

Asymptotic two-sample Kolmogorov-Smirnov test

data: cnt.1 and cnt.2

D = 0.59823, p-value < 2.2e-16


alternative hypothesis: two-sided

Possiamo vedere come il p-value ci confermi quanto detto prima, le due funzioni di ripartizione empiriche sono molto diverse tra loro dunque non possiamo accettare l'ipotesi che siano uguali.

4.2 Correlazione

4.2.1 Variabili Quantitative

Torniamo a considerare solo le osservazioni relative al 2012 e prendiamo in considerazione una Variabile Casuale Bivariata (X,Y) ovvero una variabile casuale che assume contemporaneamente le determinazioni delle variabili X=cnt e Y=hum. Come prima cosa rappresentiamo il diagramma di dispersione con le curve di livello.



Riportiamo le medie.

```
> mean(dati$hum)
```

```
[1] 0.6121664
```

```
> mean(dati$cnt)
```

```
[1] 5599.934
```

Da questo grafico possiamo dedurre che la nostra Variabile Casuale Bivariata non sia distribuita Normalmente (per esserlo le curve di livello sarebbero dovute essere delle ellissi concentriche centrate sui valori medi delle due variabili), questo implica che nel caso accettassimo l'ipotesi che il coefficiente di correlazione sia pari a zero questo non basterebbe per dire che le componenti marginali X ed Y siano Indipendenti. Facciamo il test per l'Indipendenza di Pearson (approccio classico) con $H_0: \rho = 0$.

```
> cor.test(dati$hum, dati$cnt, method = "pearson")
```

Pearson's product-moment correlation

```
data: dati$hum and dati$cnt
t = -1.7021, df = 364, p-value = 0.08959
alternative hypothesis: true correlation is not equal to 0
95 percent confidence interval:
-0.18964348 0.01377467
sample estimates:
cor
-0.08886089
```

Possiamo accettare l'Ipotesi Nulla consci del fatto che questo non basta per definire l'indipendenza tra le componenti marginali X ed Y.

Adesso facciamo altri due test per l'Indipendenza, ovvero, il test di Spearman e il test di Kendall. Questi due test sono distribution-free e vengono utilizzati quando, come nel nostro caso, abbiamo una Variabile Casuale Bivariata non distribuita normalmente.

```
> cor.test(dati$hum, dati$cnt, method = "spearman")
```

Spearman's rank correlation rho

```
data: dati$hum and dati$cnt
S = 8617860, p-value = 0.297
alternative hypothesis: true rho is not equal to 0
sample estimates:
rho
-0.05465565
```

```
> cor.test(dati$hum, dati$cnt, method = "kendall")
```

Kendall's rank correlation tau

```
data: dati$hum and dati$cnt
z = -1.1053, p-value = 0.269
alternative hypothesis: true tau is not equal to 0
sample estimates:
tau
-0.03871789
```

In entrambi i casi otteniamo un p-value molto alto, dunque anche questa volta accettiamo l'Ipotesi di indipendenza ($H_0: \rho = 0$).

4.2.2 Variabili Qualitative

Prendiamo in esame le variabili qualitative `workingday` e `weathersit`. Possiamo chiederci se tra di esse ci sia o meno un rapporto di dipendenza (chiaramente è ragionevole pensare che le due variabili siano del tutto indipendenti senza necessariamente fare un test ma lo faremo per esercizio). Per verificare l'esistenza di una dipendenza utilizzeremo il test Chi-quadrato ma prima visualizziamo la loro tabella a doppia entrata e il grafico a barre condizionato.

```
> table(dati$weathersit, dati$workingday)
```


	No	Yes
Good	77	160
Moderate	36	87
Bad	3	3

Dalla tabella a doppia entrata possiamo notare come alcune frequenze siano molto basse. Adesso facciamo la tabella delle frequenze attese per vedere se ci sono celle con frequenze < 1 .

```
> chisq.test(table(dati$weathersit, dati$workingday))$expected
```

	No	Yes
Good	75.114754	161.885246
Moderate	38.983607	84.016393
Bad	1.901639	4.098361

Non ci sono frequenze attese < 1 ed n è maggiore di 30 dunque l'approssimazione della distribuzione Chi-quadrato per il calcolo del p-value è abbastanza affidabile.



Adesso facciamo il test Chi-quadrato ponendo come Ipotesi l'indipendenza fra le due variabili, ovvero $H_0: \pi_{jl} = \pi_{j+} \cdot \pi_{+l}$ per ogni (j,l) .

```
> chisq.test(table(dati$weathersit , dati$workingday))
```

Pearson's Chi-squared test

```
data: table(dati$weathersit , dati$workingday)
X-squared = 1.3323, df = 2, p-value = 0.5137
```

Possiamo vedere che il p-value assume valore 0.5137 dunque accettiamo l'Ipotesi Nulla, c'è modo di credere che le due variabili siano indipendenti. Per completezza effettuiamo anche il test esatto di Fisher.

```
> fisher.test(table(dati$weathersit , dati$workingday))
```


Fisher's Exact Test for Count Data

```
data: table(dati$weathersit , dati$workingday)
p-value = 0.4688
alternative hypothesis: two.sided
```

Anche il test esatto di Fisher ci conferma che le due variabili siano Indipendenti.


4.3 Analisi della varianza

Anche qui analizzeremo la variabile `cnt` ma questa volta terremo conto solo dei dati relativi al 2012 e realizzeremo una partizione differente del dataset. Per effettuare la partizione useremo infatti la variabile `weekday` e dunque otterremo 7 campioni indipendenti la cui analisi avverrà per mezzo dell'analisi della varianza. Per cominciare rappresentiamo i diagrammi a scatole e baffi della variabile `cnt` relativi ai 7 giorni della settimana.



Leggendo i diagrammi da sinistra verso destra possiamo notare come il range interquartile vada prima riducendosi raggiungendo il suo minimo il giovedì per poi tornare ad aumentare raggiungendo il suo massimo domenica. La mediana invece prima aumenta, raggiungendo il suo massimo giovedì, e poi diminuisce raggiungendo il suo minimo domenica. Dunque, considerando che il numero dei differenti giorni della settimana sono più o meno uguali fra loro (il numero dei lunedì è più o meno uguale al numero dei martedì e così via), è possibile affermare che il maggior numero di clienti si concentri nei giorni centrali della settimana.

Adesso effettuiamo le stime di nucleo delle funzioni di densità della variabile nei 7 campioni usando per ciascuno un parametro di smorzamento diverso.



Dalle funzioni di densità stimate abbiamo conferma di quanto detto nell'analisi dei diagrammi a scatole e baffi. Adesso facciamo l'analisi della varianza ponendo come Ipotesi Nulla l'uguaglianza delle medie dei 7 campioni ($H_0: \mu_1 = \mu_2 = \dots = \mu_7$).

```
> summary(aov(dati$cnt ~ dati$weekday))
```

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
dati\$weekday	6	4.117e+07	6861010	2.186	0.0437 *
Residuals	359	1.127e+09	3138135		

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1

Il p-value ottenuto ci porta a rifiutare l'ipotesi Nulla dunque possiamo affermare che il giorno della settimana incide sul numero di clienti. Per vedere da quali coppie di medie dipende il rifiuto utilizziamo il test di Tukey.

```
> TukeyHSD(aov(dati$cnt ~ dati$weekday), "dati$weekday")
```

Tukey multiple comparisons of means
95% family-wise confidence level

Fit: aov(formula = dati\$cnt ~ dati\$weekday)

\$ 'dati\$weekday' :

	diff	lwr	upr	p adj
Tuesday-Monday	359.28846	-665.9785	1384.55542	0.9445902
Wednesday-Monday	649.82692	-375.4400	1675.09388	0.4954141
Thursday-Monday	783.75000	-241.5170	1809.01696	0.2632470
Friday-Monday	686.46154	-338.8054	1711.72850	0.4258347
Saturday-Monday	538.00000	-487.2670	1563.26696	0.7104724
Sunday-Monday	-157.15094	-1177.5240	863.22211	0.9993126
Wednesday-Tuesday	290.53846	-739.5992	1320.67608	0.9809930
Thursday-Tuesday	424.46154	-605.6761	1454.59915	0.8854347
Friday-Tuesday	327.17308	-702.9645	1357.31069	0.9654737
Saturday-Tuesday	178.71154	-851.4261	1208.84915	0.9986456
Sunday-Tuesday	-516.43940	-1541.7064	508.82756	0.7486098
Thursday-Wednesday	133.92308	-896.2145	1164.06069	0.9997415
Friday-Wednesday	36.63462	-993.5030	1066.77223	0.9999999
Saturday-Wednesday	-111.82692	-1141.9645	918.31069	0.9999098
Sunday-Wednesday	-806.97787	-1832.2448	218.28909	0.2308142
Friday-Thursday	-97.28846	-1127.4261	932.84915	0.9999602
Saturday-Thursday	-245.75000	-1275.8876	784.38761	0.9921166
Sunday-Thursday	-940.90094	-1966.1679	84.36602	0.0959731
Saturday-Friday	-148.46154	-1178.5992	881.67608	0.9995307
Sunday-Friday	-843.61248	-1868.8794	181.65448	0.1852205
Sunday-Saturday	-695.15094	-1720.4179	330.11602	0.4098309

Dal test non risultano intervalli che non contengono lo zero però è possibile vederne alcuni in cui è presente un forte sbilanciamento tra limite inferiore e limite superiore (Es. lwr negativo ma piccolo e upr positivo ma molto grande). Gli intervalli in questione sono Thursday-Monday, Sunday-Wednesday, Sunday-Thursday e Sunday-Friday. Un altro test da poter implementare è quello di Kruskal-Wallis.

```
> kruskal.test(dati$cnt ~ dati$weekday)
```

Kruskal-Wallis rank sum test

data: dati\$cnt by dati\$weekday

Kruskal-Wallis chi-squared = 12.834, df = 6, p-value = 0.04575

Il risultato è molto simile a quello ottenuto con l'analisi della varianza e dunque ci porta a rifiutare l'Ipotesi Nulla.

5 Regressione

5.1 Regressione Lineare

Vogliamo verificare se tra il numero totale di clienti (cnt) e la temperatura (temp) vi sia una relazione lineare. Chiaramente è logico pensare ci sia non solo una relazione lineare ma anche che essa sia positiva (all'aumentare della temperatura aumenta il numero di persone che con o senza abbonamento noleggiavano la bici) ma vogliamo provarlo. Per prima cosa stimiamo i parametri del modello di regressione lineare.

```
> lm(dati$cnt ~ dati$temp)
```


Call:

```
lm(formula = dati$cnt ~ dati$temp)
```


Coefficients:

(Intercept)	dati\$temp
3179.5	154.2

Come previsto la retta di regressione stimata ha un'inclinazione positiva. Adesso rappresentiamo graficamente il diagramma di dispersione delle due variabili e lo corrediamo con la retta di regressione appena stimata.




Una volta creato il modello di regressione procediamo con la sua analisi attraverso una serie di grafici che, guardando il modello da diverse prospettive, mettono in risalto alcuni suoi aspetti.



In alto a sinistra possiamo vedere il Diagramma di Anscombe che ci mostra come si discostano le singole unità osservate dai valori stimati dal modello. Possiamo vedere che i punti si distribuiscono non proprio in modo casuale denotando una non buona adattabilità dei dati al modello. Inoltre abbiamo tre giorni del 2012 (precisamente il 113esimo, il 189esimo e il 303esimo giorno) in cui si sono avuti pochi clienti rispetto alle temperature medie di quelle giornate (infatti abbiamo alti errori negativi). In basso a sinistra si riportano le radici dei valori assoluti dei residui standardizzati. In alto a destra si riporta il diagramma quantile-quantile in cui vengono riportati i residui standardizzati ordinati rispetto ai quantili della distribuzione Normale Standardizzata dove possiamo vedere che i punti si distribuiscono per buona parte lungo la bisettrice rendendo credibile l'ipotesi di Normalità. Per finire in basso a destra abbiamo il diagramma con le distanze di Cook dove vediamo quali sono i giorni che impattano maggiormente sul nostro modello (un modello lineare è fortemente influenzato dagli outliers proprio per via della sua rigidità).

Presentiamo nuovamente il diagramma di dispersione con la retta di regressione evidenziando questa volta anche le osservazioni critiche che sono state evidenziate nei 4 grafici precedenti.



Adesso verifichiamo la validità del modello considerando la seguente Ipotesi Nulla, $H_0: \beta_1 = 0$ (Nessun legame lineare fra le variabili).

```
> summary(lm(dati$cnt ~ dati$temp))
```

Call:

```
lm(formula = dati$cnt ~ dati$temp)
```

Residuals:

Min	1Q	Median	3Q	Max
-5113.4	-765.2	-33.8	955.7	2676.5

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	3179.531	140.690	22.60	<2e-16 ***
dati\$temp	154.246	7.933	19.45	<2e-16 ***

Signif. codes: 0 *** 0.001 ** 0.01 * 0.05 . 0.1

Residual standard error: 1254 on 364 degrees of freedom
Multiple R-squared: 0.5095, Adjusted R-squared: 0.5082
F-statistic: 378.1 on 1 and 364 DF, p-value: < 2.2e-16

Come possiamo osservare entrambi i coefficienti (Intercetta e Coefficiente Angolare) risultano significativi dunque rifiutiamo l'Ipotesi Nulla. La varianza spiegata dal modello è circa il 50% ma adesso facciamo nuovamente il test con il modello privo di intercetta.

```
> summary(lm(dati$cnt ~ -1 + dati$temp))
```

Call:
lm(formula = dati\$cnt ~ -1 + dati\$temp)

Residuals:

Min	1Q	Median	3Q	Max
-5327.4	-619.9	981.2	2048.3	4116.0

Coefficients:


	Estimate	Std. Error	t value	Pr(> t)
dati\$temp	312.858	5.723	54.66	<2e-16 ***

Signif. codes: 0 *** 0.001 ** 0.01 * 0.05 . 0.1

Residual standard error: 1942 on 365 degrees of freedom
Multiple R-squared: 0.8911, Adjusted R-squared: 0.8908
F-statistic: 2988 on 1 and 365 DF, p-value: < 2.2e-16

Possiamo notare come in questo caso la varianza spiegata dal modello salga quasi al 90%, dunque otteniamo un modello ancora migliore.


Vediamo adesso un modello di regressione più flessibile ovvero la regressione lineare locale. Questa tipologia di regressione l'abbiamo già incontrata e come abbiamo detto in precedenza essa a differenza del modello di regressione lineare classico si adatta localmente alle osservazioni.



Con questo modello appare molto più chiara la relazione fra le due variabili. All'aumentare della temperatura il numero di clienti aumenta ma questo avviene fino al raggiungimento di una temperatura "critica" oltre la quale il numero di clienti diminuisce. Questo è anche logico se ci pensiamo, temperature eccessivamente basse o eccessivamente alte disincentivano il noleggio di biciclette.

5.1.1 Regressione con trasformati

Osservando la disposizione dei punti nel diagramma di dispersione delle variabili casual (clienti occasionali) e cnt (clienti totali) può venire l'intuizione che un buon predittore della variabile cnt possa essere il logaritmo di casual.



Dunque reputo opportuno effettuare una trasformazione logaritmica della variabile casual e fare un'analisi del modello di regressione lineare ottenuto in seguito alla trasformazione.

```
> summary(lm(cnt ~ log(casual)))
```

Call:

```
lm(formula = cnt ~ log(casual))
```

Residuals:

Min	1Q	Median	3Q	Max
-3857.3	-624.0	139.1	825.4	3003.9


Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-3991.02	416.07	-9.592	<2e-16 ***
log(casual)	1455.83	62.51	23.289	<2e-16 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1

Residual standard error: 1135 on 364 degrees of freedom
Multiple R-squared: 0.5984, Adjusted R-squared: 0.5973
F-statistic: 542.4 on 1 and 364 DF, p-value: $< 2.2e-16$

Dati i valori dei p-value possiamo confermare il legame logaritmico presente tra le due variabili. Adesso rappresentiamo il diagramma di dispersione con la relativa funzione di regressione che abbiamo stimato.



5.1.2 Regressione di Poisson

Adesso prendiamo in considerazione sempre le variabili casual e cnt ma questa volta poniamo cnt come regressore e casual come variabile di risposta. Poiché la variabile di risposta assume solo valori interi positivi possiamo considerare tali valori come realizzazioni di Variabili Casuali di Poisson e possiamo realizzare una regressione di Poisson.

```
> summary(glm(dati$casual ~ dati$cnt, poisson))
```

Call:

```
glm(formula = dati$casual ~ dati$cnt, family = poisson)
```

Coefficients:

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	4.875e+00	7.800e-03	625.0	<2e-16 ***
dati\$cnt	3.382e-04	1.181e-06	286.2	<2e-16 ***

Signif. codes: 0 *** 0.001 ** 0.01 * 0.05 . 0.1

(Dispersion parameter for poisson family taken to be 1)

Null deviance: 196904 on 365 degrees of freedom
 Residual deviance: 98209 on 364 degrees of freedom
 AIC: 101297

Number of Fisher Scoring iterations: 5

Ad una prima occhiata si potrebbe pensare che questo sia un buon modello, del resto entrambi i coefficienti stimati risultano essere significativi, il problema sta nella devianza residua. La devianza residua dovrebbe essere un valore prossimo al numero di gradi di libertà ma nel nostro caso è un valore molto maggiore; questo significa che è presente super dispersione e dunque il modello è sì buono ma non è in grado di spiegare adeguatamente la variazione osservata nei dati. A questo punto usiamo un metodo di quasi-verosimiglianza.

```
> summary(glm(dati$casual ~ dati$cnt, quasipoisson))
```

Call:

```
glm(formula = dati$casual ~ dati$cnt, family = quasipoisson)
```

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	4.875e+00	1.346e-01	36.22	<2e-16 ***
dati\$cnt	3.382e-04	2.039e-05	16.59	<2e-16 ***

Signif. codes: 0 *** 0.001 ** 0.01 * 0.05 . 0.1


(Dispersion parameter for quasipoisson family taken to be 297.7634)

Null deviance: 196904 on 365 degrees of freedom
 Residual deviance: 98209 on 364 degrees of freedom
 AIC: NA

Number of Fisher Scoring iterations: 5

Il parametro di dispersione così elevato ci conferma la presenza di super dispersione, infatti il modello stima che la varianza dei dati sia circa 298 volte quella

stimata dal modello di Poisson. Rappresentiamo graficamente il diagramma di dispersione con la relativa funzione di regressione stimata.



5.1.3 Regressione Logistica

Adesso consideriamo la relazione che intercorre tra le variabili casual e workingday. La variabile workingday è la nostra variabile di risposta ed essendo una variabile dicotomica possiamo usare come modello lineare generalizzato una regressione logistica. Analizziamo dunque la dipendenza del numero di clienti occasionali dal tipo di giorno (lavorativo o festivo).

```
> summary(glm(dati$workingday ~ dati$casual, binomial))
```

Call:

```
glm(formula = dati$workingday ~ dati$casual, family = binomial)
```

Coefficients:

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	2.7770118	0.2725228	10.190	<2e-16 ***

```
dati$casual -0.0018235  0.0002155  -8.461  <2e-16 ***
```


```
Signif. codes:  0      ***      0.001      **      0.01      *      0.05      .      0.1
```

(Dispersion parameter for binomial family taken to be 1)

```
Null deviance: 457.16  on 365  degrees of freedom
Residual deviance: 346.00  on 364  degrees of freedom
AIC: 350
```

Number of Fisher Scoring iterations: 4

L'analisi del modello di regressione logistica ci porta a dire che il modello si adegua bene ai nostri dati, procediamo col visualizzare il diagramma di dispersione con la relativa funzione di regressione logistica stimata.



Il modello stimato ci dice che all'aumentare del numero di clienti occasionali accumulati nel corso di una giornata diminuisce la probabilità che quello sia un giorno lavorativo. Questo significa che chi non ha un abbonamento predilige i giorni festivi per noleggiare una bici. Viene spontaneo chiedersi se vale lo stesso per chi possiede un abbonamento. Verifichiamo.

```
> summary(glm(dati$workingday ~ dati$registered, binomial))
```

```
Call:
glm(formula = dati$workingday ~ dati$registered, family = binomial)


Coefficients:
              Estimate Std. Error z value Pr(>|z|)
(Intercept)  -2.477e+00  4.386e-01  -5.647 1.63e-08 ***
dati$registered  7.398e-04  9.853e-05   7.509 5.98e-14 ***
---
Signif. codes:  0   ***   0.001   **   0.01   *   0.05   .   0.1

(Dispersion parameter for binomial family taken to be 1)

Null deviance: 457.16  on 365  degrees of freedom
Residual deviance: 384.70  on 364  degrees of freedom
AIC: 388.7

Number of Fisher Scoring iterations: 4
```

Anche in questo caso il modello si adatta molto bene.



Possiamo notare come per i possessori di abbonamento il modello ci dice tutto il contrario. All'aumentare del numero di clienti abbonati di una giornata

aumenta la probabilità che quello sia un giorno lavorativo. Dunque i clienti che si abbonano lo fanno perché hanno necessità di spostarsi per esigenze lavorative mentre chi non sente il bisogno di abbonarsi non lo fa perché a lavoro ci va con altri mezzi ed usa la bici nei giorni festivi.

5.2 Regressione multipla

Il numero di clienti giornalieri può dipendere da diversi fattori come la temperatura, la temperatura percepita, il vento, l'umidità e il numero di clienti occasionali, dunque adesso svilupperemo un modello di regressione lineare multiplo con tali regressori. Verifichiamo se il modello ottenuto usando questi regressori è solido.

```
> summary(lm(dati$cnt ~ dati$temp + dati$atemp + dati$hum +
  dati$windspeed + dati$casual))
```

Call:

```
lm(formula = dati$cnt ~ dati$temp + dati$atemp + dati$hum +
  dati$windspeed + dati$casual)
```

Residuals:

Min	1Q	Median	3Q	Max
-3451.0	-646.4	92.5	750.6	2207.0

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	5.510e+03	3.856e+02	14.292	< 2e-16 ***
dati\$temp	2.471e+01	4.128e+01	0.599	0.5497
dati\$atemp	7.355e+01	3.332e+01	2.208	0.0279 *
dati\$hum	-2.467e+03	4.438e+02	-5.558	5.33e-08 ***
dati\$windspeed	-5.499e+01	1.154e+01	-4.765	2.75e-06 ***
dati\$casual	7.344e-01	8.932e-02	8.223	3.65e-15 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1

Residual standard error: 1066 on 360 degrees of freedom
 Multiple R-squared: 0.6499, Adjusted R-squared: 0.6451
 F-statistic: 133.7 on 5 and 360 DF, p-value: < 2.2e-16

Possiamo subito notare come le variabili temp e atemp siano entrambe poco significative poiché il loro p-value ci porta ad accettare l'ipotesi che il loro coefficiente sia nullo. Questo però potrebbe essere dovuto al fatto che sono due variabili molto simili tra loro (temperatura e temperatura percepita) dunque danno praticamente le stesse informazioni. Per ridurre il modello all'essenziale e mantenere soltanto i regressori più significativi usiamo il criterio di Akaike.

```
> summary(step(lm(dati$cnt ~ dati$temp + dati$atemp + dati$hum +
dati$windspeed + dati$casual)))
```

Start: AIC=5108.96

```
dati$cnt ~ dati$temp + dati$atemp + dati$hum + dati$windspeed +
ati$casual
```

	Df	Sum of Sq	RSS	AIC
— dati\$temp	1	407069	409210375	5107.3
<none>			408803306	5109.0
— dati\$atemp	1	5533733	414337039	5111.9
— dati\$windspeed	1	25782223	434585528	5129.3
— dati\$hum	1	35074974	443878279	5137.1
— dati\$casual	1	76780808	485584114	5170.0

Step: AIC=5107.32

```
dati$cnt ~ dati$atemp + dati$hum + dati$windspeed + dati$casual
```

	Df	Sum of Sq	RSS	AIC
<none>			409210375	5107.3
— dati\$windspeed	1	25387724	434598099	5127.4
— dati\$hum	1	35419876	444630252	5135.7
— dati\$casual	1	77370092	486580467	5168.7
— dati\$atemp	1	224906732	634117107	5265.6

Call:

```
lm(formula = dati$cnt ~ dati$atemp + dati$hum + dati$windspeed +
dati$casual)
```

Residuals:

Min	1Q	Median	3Q	Max
−3452.8	−626.5	94.7	750.1	2725.9

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	5.580e+03	3.671e+02	15.201	< 2e−16 ***
dati\$atemp	9.310e+01	6.609e+00	14.086	< 2e−16 ***
dati\$hum	−2.477e+03	4.431e+02	−5.590	4.49e−08 ***
dati\$windspeed	−5.397e+01	1.140e+01	−4.733	3.19e−06 ***
dati\$casual	7.366e−01	8.916e−02	8.262	2.76e−15 ***


Signif. codes: 0 *** 0.001 ** 0.01 * 0.05 . 0.1

Residual standard error: 1065 on 361 degrees of freedom

Multiple R-squared: 0.6496, Adjusted R-squared: 0.6457

F-statistic: 167.3 on 4 and 361 DF, p-value: < 2.2e−16

Qui abbiamo la conferma di quanto detto prima. Usando questo criterio eliminiamo il regressore relativo alla temperatura mantenendo tutti gli altri. E' molto importante notare come eliminando un regressore il coefficiente R-quadro diminuisca ma il coefficiente R-quadro aggiustato aumenti. Questo è dovuto al fatto che in un modello di regressione multiplo il coefficiente R-quadro è sensibile al numero di regressori dunque anche dei regressori "inutili" o "doppioni" come la nostra variabile temp ne aumentano il valore. Il coefficiente R-quadro aggiustato non è sensibile al numero di regressori ed è per questo che nel confrontare i due modelli consideriamo solo lui e non il semplice R-quadro. Adesso analizziamo il modello visualizzando alcuni diagrammi.



Notiamo la presenza di 3 outliers ovvero i giorni 189, 190 e 303. Queste sono le osservazioni che si discostano maggiormente dal nostro modello e che impattano maggiormente sul nostro iperpiano di previsione. Procediamo ad eliminare queste osservazioni.

```
> summary(lm(dati$cnt ~ dati$atemp + dati$hum + dati$windspeed +
dati$casual, subset = (1:length(cnt) != 189 & 190 & 303)))
```

Call:

```
lm(formula = dati$cnt ~ dati$atemp + dati$hum + dati$windspeed +
dati$casual, subset = (1:length(cnt) != 189 & 190 & 303))
```

Residuals:

Min	1Q	Median	3Q	Max
-3352.0	-635.1	84.9	724.8	2760.9

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	5.632e+03	3.624e+02	15.540	< 2e-16 ***
dati\$atemp	9.569e+01	6.566e+00	14.574	< 2e-16 ***
dati\$hum	-2.579e+03	4.381e+02	-5.887	9.03e-09 ***
dati\$windspeed	-5.447e+01	1.125e+01	-4.842	1.91e-06 ***
dati\$casual	7.228e-01	8.805e-02	8.209	4.02e-15 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1

Residual standard error: 1050 on 360 degrees of freedom
Multiple R-squared: 0.6598, Adjusted R-squared: 0.6561
F-statistic: 174.6 on 4 and 360 DF, p-value: < 2.2e-16

Eliminando queste osservazioni passiamo da un R-quadro aggiustato pari a 0.6457 ad uno pari a 0.6561, dunque guadagniamo qualcosa in termini di varianza spiegata dal modello.

Adesso nel nostro modello introduciamo anche una relazione tra variabili, ovvero il prodotto tra la temperatura percepita e il numero di clienti occasionali.

```
> summary(lm(dati$cnt ~ dati$windspeed + dati$hum + dati$atemp *  
  dati$casual))
```

Call:

```
lm(formula = dati$cnt ~ dati$windspeed + dati$hum + dati$atemp *  
  dati$casual)
```

Residuals:

Min	1Q	Median	3Q	Max
-3324.7	-522.1	81.5	605.1	1920.2

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	4.811e+03	3.540e+02	13.590	< 2e-16 ***
dati\$windspeed	-4.931e+01	1.058e+01	-4.661	4.44e-06 ***
dati\$hum	-2.481e+03	4.104e+02	-6.046	3.71e-09 ***
dati\$atemp	1.462e+02	9.155e+00	15.970	< 2e-16 ***
dati\$casual	2.016e+00	1.837e-01	10.978	< 2e-16 ***
dati\$atemp:dati\$casual	-7.024e-02	9.004e-03	-7.801	6.73e-14 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1

Residual standard error: 986.1 on 360 degrees of freedom

Multiple R-squared: 0.7002, Adjusted R-squared: 0.6961
 F-statistic: 168.2 on 5 and 360 DF, p-value: < 2.2e-16

Il coefficiente stimato per la variabile di interazione appare significativo e possiamo notare anche un aumento dell'R-quadro aggiustato rispetto all'ultimo modello stimato (dopo l'eliminazione degli outliers). Questo significa che introducendo questa relazione fra la variabile atemp e casual ottengo un modello migliore. Infine eliminiamo anche qui gli outliers ed otteniamo il seguente modello.

```
> summary(lm(dati$cnt ~ dati$windspeed + dati$hum + dati$atemp *
  dati$casual, subset = (1:length(cnt) != 189 & 190 & 303)))
```

Call:

```
lm(formula = dati$cnt ~ dati$windspeed + dati$hum + dati$atemp *
  dati$casual, subset = (1:length(cnt) != 189 & 190 & 303))
```

Residuals:

Min	1Q	Median	3Q	Max
-3310.3	-530.5	75.7	611.1	1918.7

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)	
(Intercept)	4.878e+03	3.512e+02	13.888	< 2e-16	***
dati\$windspeed	-4.986e+01	1.047e+01	-4.761	2.80e-06	***
dati\$hum	-2.564e+03	4.073e+02	-6.296	8.90e-10	***
dati\$atemp	1.466e+02	9.063e+00	16.172	< 2e-16	***
dati\$casual	1.964e+00	1.827e-01	10.745	< 2e-16	***
dati\$atemp:dati\$casual	-6.795e-02	8.948e-03	-7.594	2.71e-13	***

Signif. codes: 0 *** 0.001 ** 0.01 * 0.05 . 0.1

Residual standard error: 976.2 on 359 degrees of freedom
 Multiple R-squared: 0.7069, Adjusted R-squared: 0.7028
 F-statistic: 173.2 on 5 and 359 DF, p-value: < 2.2e-16

Il modello ottenuto spiega circa il 70% della variabilità dei dati. Questo modello non sarà di certo uno dei migliori ma comunque abbiamo visto come con qualche modifica siamo riusciti ad ottenere un modello che presenta un R-quadro più alto.

5.2.1 Modelli additivi generalizzati

Supponiamo adesso che la nostra variabile di risposta (cnt) dipenda da una somma di trasformazioni non note dei regressori usati nel modello precedente. In questo caso useremo un modello additivo generalizzato.

```
> summary(gam(dati$cnt ~ s(dati$atemp) + s(dati$hum)
+ s(dati$windspeed)+ s(dati$casual)))
```

Family: gaussian

Link function: identity

Formula:

```
dati$cnt ~ s(dati$atemp) + s(dati$hum) + s(dati$windspeed) +
s(dati$casual)
```

Parametric coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	5599.93	43.95	127.4	<2e-16 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1

Approximate significance of smooth terms:


	edf	Ref. df	F	p-value
s(dati\$atemp)	7.047	8.120	22.26	< 2e-16 ***
s(dati\$hum)	2.933	3.714	22.38	< 2e-16 ***
s(dati\$windspeed)	1.000	1.000	22.38	3.46e-06 ***
s(dati\$casual)	6.341	7.491	10.14	< 2e-16 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1

R-sq.(adj) = 0.779 Deviance explained = 78.9%

GCV = 7.4435e+05 Scale est. = 7.0709e+05 n = 366

In questo modo otteniamo un modello con un R-quadro aggiustato di circa 0.78 ed un modello che spiega circa il 78% della variabilità dei dati incomincia ad essere un buon modello. Diamo un'occhiata ai grafici delle quattro funzioni.



Di seguito riportiamo gli effetti dei regressori sulla variabile dipendente:

- **Variabile atemp:** Questa variabile per temperature basse ha un impatto negativo sulla variabile dipendente, per temperature miti diventa positivo ed infine per temperature elevate torna rapidamente ad influire negativamente. Questo lo avevamo già visto, temperature troppo basse o troppo alte influenzano negativamente il numero di persone che noleggiavano bici.
- **Variabile hum:** Fino a circa il 65% di umidità la variabile ha un impatto positivo sulla variabile di risposta ma superata questa soglia diventa negativo.
- **Variabile Windspeed:** All'aumentare dell'intensità del vento il suo andamento è lineare decrescente.
- **Variabile Casual:** Anche in questo caso abbiamo un andamento lineare ma questa volta crescente, superata la soglia di circa 750 clienti occasionali l'impatto di questa variabile sul numero complessivo di clienti diventa positivo.

5.2.2 Regressione Logistica Multipla

In questo elaborato abbiamo già visto due modelli logistici, entrambi con la medesima variabile di risposta dicotomica `workingday` ed un solo regressore, rispettivamente `casual` e `registered5.1.3`. Adesso considereremo sempre `workingday` come variabile di risposta ma introdurremo nel modello più regressori, creando così un modello di regressione logistica multiplo. I regressori che inseriremo nel modello sono la temperatura, l'umidità e il numero complessivo di clienti. Sappiamo bene che le prime due variabili sono del tutto ininfluenti nella determinazione della tipologia di giornata (lavorativa o feriale) ma le inseriamo per vedere come il software riconosce le variabili non significative e le elimina dal modello.

```
> summary(step(glm(workingday ~ temp + hum + cnt, binomial)))
```

```
Start:  AIC=459.12
workingday ~ temp + hum + cnt
```

	Df	Deviance	AIC
— hum	1	451.57	457.57
— temp	1	451.86	457.86
<none>		451.12	459.12
— cnt	1	455.86	461.86

```
Step:  AIC=457.57
workingday ~ temp + cnt
```

	Df	Deviance	AIC
— temp	1	452.07	456.07
<none>		451.57	457.57
— cnt	1	455.87	459.87

```
Step:  AIC=456.07
workingday ~ cnt
```

	Df	Deviance	AIC
<none>		452.07	456.07
— cnt	1	457.16	459.16

```
Call:
glm(formula = workingday ~ cnt, family = binomial)
```

```
Coefficients:
              Estimate Std. Error z value Pr(>|z|)
(Intercept) -7.881e-03  3.575e-01  -0.022   0.9824
cnt          1.405e-04  6.221e-05   2.258   0.0239 *
```


Signif. codes: 0 *** 0.001 ** 0.01 * 0.05 . 0.1

(Dispersion parameter for binomial family taken to be 1)

Null deviance: 457.16 on 365 degrees of freedom
Residual deviance: 452.07 on 364 degrees of freedom
AIC: 456.07

Number of Fisher Scoring iterations: 4

Come avevamo previsto nel modello resta solo la variabile cnt. Questa variabile come sappiamo è l'unione delle variabili casual e registered ed abbiamo visto nei due modelli logistici analizzati in precedenza che, mentre casual ha un effetto negativo sulla variabile di risposta (all'aumentare dei clienti occasionali diminuisce la probabilità che quel giorno sia lavorativo) registered ha un effetto positivo (all'aumentare del numero di abbonati che nolegciano una bici aumenta la probabilità che sia un giorno lavorativo). Dall'analisi del modello possiamo vedere che cnt ha un effetto positivo ma esso non è altro che il frutto degli effetti delle due variabili che la compongono. Inoltre dobbiamo dire che la riduzione della devianza risulta veramente minima (si passa da una null deviance di 457.16 ad una residual deviance di 452.07) e questo dimostra che il modello non si adatta molto bene ai dati. Vediamo una rappresentazione grafica.




Il grafico ci conferma quanto detto prima, il modello non è solido.


6 Metodi di smorzamento

6.1 Stimatore di nucleo


Adesso condurremo un'indagine esplorativa sulla funzione di densità della variabile windspeed. Tale funzione potrebbe essere stimata in maniera grossolana da un istogramma ma, poiché noi vogliamo ottenere risultati grafici più precisi, stimeremo tale funzione usando i metodi di smorzamento. Un metodo di smorzamento, a differenza dell'istogramma, crea una rappresentazione della funzione di densità concentrata sul nucleo più o meno liscia in base al valore che assume il parametro di smorzamento h (all'aumentare del parametro la funzione stimata sarà più liscia). Dunque scegliamo tre valori diversi di h così da vedere cosa succede alla funzione ($h = 5, 1, 0.5$).



h = 1



h = 0.5



Dalle funzioni di densità ottenute possiamo osservare empiricamente come al diminuire del parametro di smorzamento h la funzione di densità della variabile diventi sempre più ruvida avvicinandosi così alla funzione di densità empirica. Come sappiamo più la funzione risulta liscia e maggiori saranno le informazioni che perderemo (aumenta la distorsione dello stimatore di nucleo), dunque è giusto usare dei valori del parametro di smorzamento che rappresentino un buon compromesso tra distorsione dello stimatore e smorzamento della funzione. Per fare ciò calcoleremo il parametro h servendoci dei metodi cross-validation e plug-in.


```
> hcv(dati$windspeed)
```


```
[1] 1.028668
```

```
hsj(dati$windspeed)
```

```
[1] 1.370939
```

Adesso vediamo graficamente cosa comporta l'utilizzo di un metodo piuttosto che l'altro.






Con entrambi i metodi otteniamo un parametro h relativamente alto, il che ci porta a stimare due funzioni di densità abbastanza lisce.


6.2 Stimatore di nucleo bivariato

Possiamo utilizzare i metodi di smorzamento anche per stimare la funzione di densità congiunta di due variabili quantitative continue. In questo caso useremo solo il metodo cross-validation e stimeremo la funzione di densità congiunta delle variabili temp e windspeed ottenendo il seguente grafico tridimensionale.


Kernel density estimation ('CV' h1 = 1.938815, h2 = 1.227147)



Come possiamo osservare dal grafico abbiamo due picchi, uno in corrispondenza di vento moderato e temperature basse ed uno in corrispondenza di vento moderato e temperature elevate. Questo è dovuto alla stagionalità dei nostri dati, la città di Washington D.C. non è soggetta a forti venti dunque i due picchi rappresentano rispettivamente la bella e la brutta stagione. Per una visione migliore possiamo sezionare a varie altezze la funzione di densità congiunta ottenendo il seguente grafico bidimensionale raffigurante le curve di livello.



Con le curve di livello confermiamo quanto detto prima ed aggiungiamo che nella bella stagione i venti tendono ad essere leggermente meno intensi. Adesso usiamo una rappresentazione grafica per toni di colori.



Questo grafico ha un impatto visivo maggiore e unito ai due grafici precedenti ci permette di avere una visione più di insieme riguardo la struttura della funzione di densità congiunta.

7 Massima Verosimiglianza

Prendiamo in esame la variabile `windspeed`. Facciamo finta che i dati che possediamo siano le osservazioni di un campione, campione estratto sotto ipotesi che la variabile `windspeed` si disponga normalmente. Le stime di massima verosimiglianza sono le seguenti:

```
> mean(dati$windspeed, na.rm = TRUE)
```

```
[1] 12.70134
```

```
> var(dati$windspeed , na.rm = TRUE)
```

```
[1] 27.44696
```

Adesso verifichiamo la validità del modello controllando i valori dei coefficienti campionari di asimmetria e curtosi (nel nostro caso per avere una distribuzione normale dovremmo ottenere entrambi i coefficienti pari a zero).


```
> skewness(dati$windspeed, na.rm = TRUE)
```

```
[1] 0.8225718
```

```
> kurtosis(dati$windspeed, na.rm = TRUE)
```

```
[1] 0.3817826
```

Abbiamo ottenuto entrambi i coefficienti positivi, dunque la variabile `windspeed` non si distribuisce normalmente ma la sua distribuzione presenta un'asimmetria positiva ed è leptocurtica (a code pesanti). Adesso vedremo anche una rappresentazione grafica di quanto detto attraverso un diagramma quantile-quantile. Con tale diagramma mettiamo a confronto le osservazioni standardizzate tramite la media e la varianza campionarie con i quantili della distribuzione normale standardizzata.



Avessimo avuto una distribuzione normale i punti si sarebbero dovuti distribuire tutti lungo la retta, in questo caso invece vediamo che i punti si discostano da essa. Nella parte superiore possiamo notare come i punti si discostano maggiormente, ciò evidenzia che la coda di destra risulta più pesante e questo conferma l'asimmetria positiva che avevamo anticipato con l'indice di asimmetria. Possiamo notare però come anche nella parte inferiore i punti si discostano, seppur in maniera meno accentuata rispetto la parte superiore, evidenziando code pesanti che sono caratterizzanti di una distribuzione leptocurtica.